

Efecto del método de integración numérica en modelos de flujo rectificado sobre distribuciones bidimensionales

Integrantes del grupo:

Tommy Bryan Loo Leon - [202510241]
Jesús Valentín Niño Castañeda - [202310452]
Leonardo Jesús Medina Gago - [202410022]
Lemuel Uziel Ramos Urbano - [202520133]
Fabricio Joaquin Rueda Zapata - [202510114]

Curso:

CC2104 Métodos Numéricos

Profesor:

[Patricia Reynoso Quispe]

Fecha de entrega:

9 de Septiembre de 2026

Efecto del método de integración numérica en modelos de flujo rectificado sobre distribuciones bidimensionales

Tommy Bryan Loo Leon^a, Jesús Valentín Niño Castañeda^a, Leonardo Jesús Medina Gago^a, Lemuel Uziel Rambos Urbano^a,
Fabricio Joaquin Rueda Zapata^a

^aUTEC, , , , ,

Abstract

The project will study a continuous flow described by a differential equation that transports samples from a simple initial distribution to a two-dimensional target distribution. Instead of training a large-scale generative image model, we will implement different test vector fields or, alternatively, a small neural network to approximate the transport field and observe how the distribution evolves over time. We will use synthetic data and evaluate how the integrator affects the trajectory, final error, and computational cost. The ultimate goal will be to evaluate the relationship between accuracy and efficiency, identifying how important it is for the trajectories to be straight or close to the ideal trajectories. The theoretical foundation of the project will be related to papers that present different variants of rectified flow, flow matching, and straighter transport trajectories.

Keywords: Flow Matching, Rectified Flow, Integración Numérica, Modelos Generativos

1. Introduction

Muchos problemas modernos requieren transformar un conjunto de puntos, generados de manera simple y aleatoria, en otro conjunto de puntos que sigue una distribución mucho más compleja. Este tipo de transformación puede describirse mediante una ecuación diferencial ordinaria que indica, en cada instante de tiempo, la velocidad con la que cada punto debe desplazarse para alcanzar su posición final. Dado que estas ecuaciones diferenciales rara vez admiten una solución analítica exacta, resulta necesario resolverlas mediante métodos numéricos de integración, cuya elección determina de manera directa tanto la precisión de la trayectoria obtenida como el costo computacional del proceso. Este problema resulta particularmente relevante en el contexto de los modelos generativos modernos, en los cuales el transporte eficiente y preciso de distribuciones de probabilidad constituye un componente central.

Para profundizar en el tema, se han seleccionado trabajos recientes y relevantes que abordan distintos enfoques y avances en Flow Matching y métodos relacionados. Estos antecedentes permiten comprender la evolución de las ideas y los desafíos que se han presentado en el área.

Como primer antecedente, Lipman et al. (2023) introdujeron Flow Matching, un marco que permite entrenar campos vectoriales para modelar el transporte continuo entre una distribución inicial y una distribución objetivo mediante ecuaciones diferenciales ordinarias. Lo interesante de su propuesta es que posibilita definir diferentes trayectorias de probabilidad y entrenar el campo de velocidad sin necesidad de simular previamente dichas trayectorias durante el entrenamiento. Además, los autores muestran que los caminos basados en transporte óptimo pueden generar muestras de forma más rápida y eficiente en comparación con otras alternativas, gracias al uso de métodos

numéricos para resolver las ODE en la fase de muestreo, lo que proporciona la base conceptual y matemática sobre la que se apoyan los modelos de transporte analizados en este proyecto.

Posteriormente, Liu et al. (2022) propusieron Rectified Flow, cuyo objetivo es aprender trayectorias de transporte lo más rectas posible entre las distribuciones inicial y final. La idea principal consiste en emplear un campo de velocidad que aproxime la trayectoria lineal que une los puntos correspondientes de ambas distribuciones. Esta característica resulta especialmente interesante desde una perspectiva numérica, ya que una trayectoria recta permite una discretización temporal mucho más gruesa sin perder precisión. Los autores demostraron que, mediante el procedimiento llamado reflow, es posible obtener trayectorias cada vez más rectas y lograr buenos resultados incluso utilizando un solo paso de Euler, lo que implica que se pueden reducir considerablemente los pasos necesarios para la integración y, en consecuencia, el tiempo requerido para generar muestras.

En esta misma línea, Pooladian et al. (2023) desarrollaron Multisample Flow Matching, una extensión que introduce acoplamientos no triviales entre muestras de las distribuciones de origen y destino. El objetivo de esta propuesta es aprovechar la estructura existente entre las muestras para construir campos vectoriales con trayectorias más rectas. Los autores demostraron que, además de reducir la varianza durante el entrenamiento, este enfoque permite generar muestras de buena calidad utilizando un menor número de evaluaciones del campo vectorial, lo que evidencia experimentalmente que la geometría de las trayectorias puede influir de manera directa en la eficiencia computacional del proceso de integración, y resalta la importancia de considerar este aspecto en el presente estudio.

De manera relacionada, Tong et al. (2024) exploraron el uso

del transporte óptimo dentro de Flow Matching a través de su propuesta llamada Optimal Transport Conditional Flow Matching. En su estudio, los autores muestran que los acoplamientos obtenidos mediante transporte óptimo permiten construir flujos más simples y estables, además de facilitar una inferencia más rápida. Estos resultados refuerzan la idea de que la manera en que se establece la correspondencia entre las distribuciones inicial y objetivo influye directamente en la complejidad del campo vectorial y, por lo tanto, en la dificultad de su resolución numérica, lo que resulta especialmente relevante para el análisis realizado en este proyecto.

Posteriormente, Yang et al. (2024) presentaron Consistency Flow Matching, una propuesta enfocada en construir trayectorias rectas mediante la aplicación de restricciones de consistencia en el campo de velocidad. A diferencia de otros enfoques que dependen principalmente de procesos iterativos para rectificar las trayectorias, esta metodología incorpora de manera explícita la consistencia de la velocidad para enlazar distintos momentos en el tiempo con un mismo destino final. Los autores argumentan que este mecanismo favorece la simplicidad de las trayectorias y posibilita una generación eficiente, requiriendo menos evaluaciones del campo vectorial. Así, su trabajo subraya que mantener trayectorias menos complejas sigue siendo clave para optimizar la velocidad de inferencia en los modelos basados en Flow Matching, aportando un enfoque novedoso en este ámbito.

Desde el enfoque teórico, Zhou and Liu (2025) analizaron el error presente en los modelos generativos desarrollados con Flow Matching. Su trabajo se centra en cómo la distribución generada se aproxima a la distribución objetivo y en qué condiciones se puede garantizar esta convergencia, utilizando como referencia la distancia de Wasserstein-2. Lo interesante de este antecedente es que permite separar claramente el error que proviene del aprendizaje del campo de velocidad de aquel que surge al resolver numéricamente la ecuación diferencial. Esta distinción resulta crucial para este proyecto, pues ayuda a entender mejor cómo el método de integración influye en la distribución final que se obtiene.

Finalmente, Xiao (2026) llevó a cabo un análisis comparativo de distintos métodos de integración numérica aplicados a modelos de Flow Matching. En su estudio, exploró alternativas como Euler, midpoint explícito, Runge-Kutta de cuarto orden y Dormand-Prince, realizando pruebas con distribuciones sintéticas bidimensionales. Al comparar la calidad de las muestras y la cantidad de evaluaciones requeridas del campo vectorial, notó que los métodos más avanzados pueden ser más eficientes sin comprometer la calidad de los resultados. De esta manera, su trabajo muestra cómo la elección del método de integración puede marcar diferencias sutiles pero importantes en el comportamiento práctico de estos modelos.

En conjunto, estos antecedentes sugieren que la eficiencia de los modelos basados en Flow Matching y Rectified Flow no depende únicamente de la capacidad del campo vectorial para transformar una distribución en otra. También influyen aspectos como la geometría de las trayectorias y el método numérico empleado para resolver la ecuación diferencial. Por esto, resulta interesante analizar cómo se comporta el modelo al mantener

constante el campo vectorial y variar únicamente el método de integración, lo que permite observar con mayor claridad cómo la discretización numérica afecta tanto la trayectoria como el resultado final y los recursos computacionales requeridos.

A pesar de los recientes y notables avances en los modelos generativos continuos, un inconveniente importante tanto de los Flujos Normalizantes Continuos (CNFs, descritos por EDOs) como de los modelos de difusión, también descritos por EDOs, es que su simulación e integración numérica requieren múltiples evaluaciones de la red neuronal para generar una muestra de alta calidad. Este proceso iterativo da como resultado tiempos de inferencia prolongados, lo que limita su eficiencia y aplicabilidad en escenarios de tiempo real. Para mitigar este inconveniente, investigaciones recientes han motivado el desarrollo de métodos que imponen propiedades de transporte óptimo (OT) en las EDOs neuronales, produciendo flujos con trayectorias más rectas que pueden integrarse con precisión utilizando un menor número de evaluaciones de la red neuronal. Sin embargo, la literatura carece de un análisis exhaustivo sobre cómo la elección específica del método de integración numérica altera la trayectoria, el error y el costo cuando se aplican estos flujos enderezados. El presente trabajo se justifica en la necesidad de llenar este vacío analizando el efecto del integrador numérico sobre modelos de flujo rectificado en un entorno controlado de distribuciones bidimensionales. Comprender la relación exacta entre la rectitud de la trayectoria, la precisión del integrador numérico y la eficiencia computacional es un paso indispensable para optimizar el despliegue de modelos generativos modernos.

Por lo expuesto, como objetivo general tenemos: modelar numéricamente el transporte continuo de muestras mediante ecuaciones diferenciales que transformen una distribución inicial simple en una distribución objetivo bidimensional, con el propósito de analizar la relación entre la precisión, la eficiencia computacional y la rectitud de las trayectorias generadas mediante diferentes campos vectoriales y métodos de integración. En base a ello desarrollamos nuestros objetivos específicos los cuales son:

1. Formular e implementar un modelo numérico basado en EDOs que represente el transporte de muestras desde una distribución inicial simple hacia una distribución objetivo bidimensional mediante campos vectoriales de prueba.
2. Evaluar el comportamiento del modelo bajo un conjunto base de parámetros, considerando la trayectoria de las muestras, el error respecto a la distribución objetivo y el costo computacional asociado al proceso de integración.
3. Analizar la robustez del modelo mediante la variación de parámetros relevantes, comparando los cambios en la precisión, la rectitud de las trayectorias y el costo computacional obtenidos bajo diferentes configuraciones.
4. Aplicar el modelo numérico al transporte de distribuciones bidimensionales para determinar la relación entre la rectitud de las trayectorias, el método de integración empleado y la eficiencia en la generación de muestras.

2. Metodología

2.1. Modelo del sistema

El fenómeno de estudio se modela mediante una ecuación diferencial ordinaria que describe el transporte continuo de una muestra:

$$\frac{dx_t}{dt} = v_\theta(x_t, t), \quad x_0 \sim p_0, \quad t \in [0, 1], \quad (1)$$

donde $x_t \in \mathbb{R}^2$ representa el estado de una muestra en el instante t , p_0 es la distribución inicial y v_θ es el campo vectorial de velocidad. La solución de esta ecuación induce una evolución de la distribución desde p_0 hacia una distribución objetivo p_1 , como se plantea en las formulaciones de Flow Matching basadas en ecuaciones diferenciales ordinarias (Lipman et al., 2023; Tong et al., 2024; Yang et al., 2024).

Para definir una trayectoria de referencia, se utiliza la interpolación condicional lineal de Flow Matching:

$$x_t = (1 - t)x_0 + tx_1, \quad (2)$$

donde x_0 y x_1 representan muestras de las distribuciones inicial y objetivo, respectivamente. Al derivar respecto del tiempo se obtiene la velocidad condicional

$$u_t(x_0, x_1) = \frac{dx_t}{dt} = x_1 - x_0. \quad (3)$$

Por consiguiente, la trayectoria condicional es una línea recta con velocidad constante. Esta construcción se encuentra en las formulaciones de Flow Matching y en los trabajos que estudian la rectitud de las trayectorias (Lipman et al., 2023; Pooladian et al., 2023).

El campo de velocidad se formula, en el enfoque de Flow Matching, mediante una función que aproxima la velocidad condicional a través de una regresión cuadrática:

$$\mathcal{L}(\theta) = \mathbb{E} \left[\|v_\theta(x_t, t) - u_t(x_0, x_1)\|^2 \right]. \quad (4)$$

Esta formulación corresponde al objetivo de Flow Matching descrito por Lipman et al. (2023); Tong et al. (2024).

El análisis numérico se concentra en la resolución de la EDO durante el transporte. Por ello, para comparar los métodos de integración se mantiene fijo el problema de transporte y se modifica únicamente el integrador empleado para aproximar la solución temporal. De esta manera, la comparación se enfoca en el efecto de la discretización numérica.

2.2. Supuestos y simplificaciones del modelo

Para la primera etapa del proyecto se consideran las siguientes simplificaciones:

- **Dimensión bidimensional:** el análisis se realiza en $\mathbb{R}^2$ para estudiar directamente la evolución y la geometría de las trayectorias. Este tipo de configuración bidimensional también aparece en experimentos comparativos de integradores para Flow Matching (Xiao, 2026).

- **Distribución inicial simple:** se emplea una distribución normal estándar como distribución de partida, siguiendo la formulación utilizada para la variable inicial en Flow Matching (Lipman et al., 2023; Xiao, 2026).
- **Intervalo temporal normalizado:** se considera $t \in [0, 1]$, intervalo utilizado en las formulaciones de interpolación y flujo continuo de los trabajos de referencia (Lipman et al., 2023; Pooladian et al., 2023; Xiao, 2026).
- **Campo fijo durante la comparación:** el campo vectorial utilizado en cada experimento se mantiene constante al cambiar el integrador. Así, el análisis se concentra en el efecto del método numérico y de su configuración.
- **Distribuciones sintéticas:** se trabaja con distribuciones bidimensionales sintéticas para mantener un entorno controlado y facilitar la observación de las trayectorias, en concordancia con el tipo de experimentos bidimensionales utilizado por Xiao (2026).

Estas simplificaciones permiten concentrar el estudio en la resolución numérica de la EDO. En esta primera entrega no se desarrolla todavía la implementación ni se presentan resultados; el énfasis se mantiene en la formulación del modelo, sus supuestos y la selección de los métodos numéricos.

2.3. Métodos numéricos propuestos

Para aproximar la solución de la EDO desde $t = 0$ hasta $t = 1$ se proponen tres métodos de integración: Euler, Runge–Kutta de cuarto orden (RK4) y Runge–Kutta 4/5 (RK45). La elección permite comparar métodos de diferente orden y, en el caso de RK45, incorporar control adaptativo del tamaño de paso (Xiao, 2026).

2.3.1. Método de Euler

El método de Euler aproxima la solución mediante

$$x_{n+1} = x_n + h v_\theta(x_n, t_n), \quad (5)$$

donde h representa el tamaño de paso. Es un método de primer orden y realiza una evaluación del campo vectorial por paso (Xiao, 2026). Se utiliza como método base para estudiar cómo la discretización temporal afecta la aproximación de la trayectoria.

2.3.2. Runge–Kutta de cuarto orden (RK4)

El método RK4 utiliza cuatro evaluaciones del campo vectorial en cada paso:

$$k_1 = f(t_n, x_n), \quad (6)$$

$$k_2 = f\left(t_n + \frac{h}{2}, x_n + \frac{h}{2}k_1\right), \quad (7)$$

$$k_3 = f\left(t_n + \frac{h}{2}, x_n + \frac{h}{2}k_2\right), \quad (8)$$

$$k_4 = f(t_n + h, x_n + hk_3). \quad (9)$$

La actualización se obtiene mediante

$$x_{n+1} = x_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \quad (10)$$

El método presenta error global de orden $O(h^4)$ y requiere cuatro evaluaciones del campo por paso (Xiao, 2026). Esto permite contrastar un método de cuarto orden con Euler manteniendo el mismo problema dinámico.

2.3.3. Runge–Kutta 4/5 (RK45)

Como tercer método se utiliza RK45, basado en un esquema Runge–Kutta embebido que permite estimar el error local y adaptar el tamaño de paso. En particular, el método Dormand–Prince 5(4), empleado como RK45 en el análisis de Xiao (2026), utiliza aproximaciones de diferente orden para estimar el error y decidir el siguiente tamaño de paso.

A diferencia de Euler y RK4, que se plantean con un tamaño de paso fijado previamente, RK45 adapta el paso según una tolerancia de error. Esto permite incluir en la comparación un integrador cuya discretización temporal se ajusta durante la resolución de la EDO (Xiao, 2026).

En conjunto, Euler, RK4 y RK45 constituyen los tres métodos numéricos que se utilizarán para resolver el mismo problema de transporte. La comparación posterior permitirá analizar cómo el orden y la estrategia de selección del paso influyen sobre la aproximación numérica y el costo asociado a la integración.

References

- Lipman, Y., Chen, R. T. Q., Ben-Hamu, H., Nickel, M., & Le, M. (2023). Flow matching for generative modeling. *Transactions on Machine Learning Research*. <https://arxiv.org/abs/2210.02747>
- Liu, X., Gong, C., & Liu, Q. (2022). Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*. <https://arxiv.org/abs/2209.03003>
- Pooladian, A.-A., Ben-Hamu, H., Domingo-Enrich, C., Amos, B., Lipman, Y., & Chen, R. T. Q. (2023). Multisample flow matching: Straightening flows with minibatch couplings. In *Proceedings of the 40th International Conference on Machine Learning*, PMLR 202, 28100–28120. <https://proceedings.mlr.press/v202/pooladian23a.html>
- Tong, A., Fatras, K., Malkin, N., Huguet, G., Zhang, Y., Rector-Brooks, J., Wolf, G., & Bengio, Y. (2024). Improving and generalizing flow-based generative models with minibatch optimal transport. *Transactions on Machine Learning Research*. <https://openreview.net/forum?id=CD9Snc73AW>
- Yang, L., Zhang, Z., Zhang, Z., Liu, X., Xu, M., Zhang, W., Meng, C., Ermon, S., & Cui, B. (2024). Consistency flow matching: Defining straight flows with velocity consistency. *arXiv preprint arXiv:2407.02398*. <https://arxiv.org/abs/2407.02398>

Zhou, Z., & Liu, W. (2025). An error analysis of flow matching for deep generative modeling. In *Proceedings of the 42nd International Conference on Machine Learning*. <https://arxiv.org/abs/2501.09674>

Xiao, H. (2026). From Euler to Dormand–Prince: ODE solvers for Flow Matching generative models. *arXiv preprint arXiv:2605.00836*. <https://arxiv.org/abs/2605.00836>