

Efecto del método de integración numérica en modelos de flujo rectificado sobre distribuciones bidimensionales

Integrantes del grupo:

Tommy Bryan Loo Leon - [202510241]
Jesús Valentín Niño Castañeda - [202310452]
Leonardo Jesús Medina Gago - [202410022]
Lemuel Uziel Ramos Urbano - [202520133]
Fabricio Joaquin Rueda Zapata - [202510114]

Curso:

CC2104 Métodos Numéricos

Profesor:

[Patricia Reynoso Quispe]

Fecha de entrega:

9 de Septiembre de 2026

Efecto del método de integración numérica en modelos de flujo rectificado sobre distribuciones bidimensionales

Tommy Bryan Loo Leon^a, Jesús Valentín Niño Castañeda^a, Leonardo Jesús Medina Gago^a, Lemuel Uziel Rambos Urbano^a,
Fabricio Joaquin Rueda Zapata^a

^aUTEC, , , , ,

Abstract

The project will study a continuous flow described by a differential equation that transports samples from a simple initial distribution to a two-dimensional target distribution. Instead of training a large-scale generative image model, we will implement different test vector fields or, alternatively, a small neural network to approximate the transport field and observe how the distribution evolves over time. We will use synthetic data and evaluate how the integrator affects the trajectory, final error, and computational cost. The ultimate goal will be to evaluate the relationship between accuracy and efficiency, identifying how important it is for the trajectories to be straight or close to the ideal trajectories. The theoretical foundation of the project will be related to papers that present different variants of rectified flow, flow matching, and straighter transport trajectories.

Keywords: Flow Matching, Rectified Flow, Integración Numérica, Modelos Generativos

1. Introduction

Muchos problemas modernos requieren transformar un conjunto de puntos, generados de manera simple y aleatoria, en otro conjunto de puntos que sigue una distribución mucho más compleja. Este tipo de transformación puede describirse mediante una ecuación diferencial ordinaria que indica, en cada instante de tiempo, la velocidad con la que cada punto debe desplazarse para alcanzar su posición final. Dado que estas ecuaciones diferenciales rara vez admiten una solución analítica exacta, resulta necesario resolverlas mediante métodos numéricos de integración, cuya elección determina de manera directa tanto la precisión de la trayectoria obtenida como el costo computacional del proceso. Este problema resulta particularmente relevante en el contexto de los modelos generativos modernos, en los cuales el transporte eficiente y preciso de distribuciones de probabilidad constituye un componente central.

Para profundizar en el tema, se han seleccionado trabajos recientes y relevantes que abordan distintos enfoques y avances en Flow Matching y métodos relacionados. Estos antecedentes permiten comprender la evolución de las ideas y los desafíos que se han presentado en el área.

Como primer antecedente, Lipman et al. (2022) introdujeron Flow Matching, un marco que permite entrenar campos vectoriales para modelar el transporte continuo entre una distribución inicial y una distribución objetivo mediante ecuaciones diferenciales ordinarias. Lo interesante de su propuesta es que posibilita definir diferentes trayectorias de probabilidad y entrenar el campo de velocidad sin necesidad de simular previamente dichas trayectorias durante el entrenamiento. Además, los autores muestran que los caminos basados en transporte óptimo pueden generar muestras de forma más rápida y eficiente en comparación con otras alternativas, gracias al uso de métodos

numéricos para resolver las ODE en la fase de muestreo, lo que proporciona la base conceptual y matemática sobre la que se apoyan los modelos de transporte analizados en este proyecto.

Posteriormente, Liu et al. (2022) propusieron Rectified Flow, cuyo objetivo es aprender trayectorias de transporte lo más rectas posible entre las distribuciones inicial y final. La idea principal consiste en emplear un campo de velocidad que aproxime la trayectoria lineal que une los puntos correspondientes de ambas distribuciones. Esta característica resulta especialmente interesante desde una perspectiva numérica, ya que una trayectoria recta permite una discretización temporal mucho más gruesa sin perder precisión. Los autores demostraron que, mediante el procedimiento llamado reflow, es posible obtener trayectorias cada vez más rectas y lograr buenos resultados incluso utilizando un solo paso de Euler, lo que implica que se pueden reducir considerablemente los pasos necesarios para la integración y, en consecuencia, el tiempo requerido para generar muestras.

En esta misma línea, Pooladian et al. (2023) desarrollaron Multisample Flow Matching, una extensión que introduce acoplamientos no triviales entre muestras de las distribuciones de origen y destino. El objetivo de esta propuesta es aprovechar la estructura existente entre las muestras para construir campos vectoriales con trayectorias más rectas. Los autores demostraron que, además de reducir la varianza durante el entrenamiento, este enfoque permite generar muestras de buena calidad utilizando un menor número de evaluaciones del campo vectorial, lo que evidencia experimentalmente que la geometría de las trayectorias puede influir de manera directa en la eficiencia computacional del proceso de integración, y resalta la importancia de considerar este aspecto en el presente estudio.

De manera relacionada, Tong et al. (2023) exploraron el uso

del transporte óptimo dentro de Flow Matching a través de su propuesta llamada Optimal Transport Conditional Flow Matching. En su estudio, los autores muestran que los acoplamientos obtenidos mediante transporte óptimo permiten construir flujos más simples y estables, además de facilitar una inferencia más rápida. Estos resultados refuerzan la idea de que la manera en que se establece la correspondencia entre las distribuciones inicial y objetivo influye directamente en la complejidad del campo vectorial y, por lo tanto, en la dificultad de su resolución numérica, lo que resulta especialmente relevante para el análisis realizado en este proyecto.

Posteriormente, Yang et al. (2024) presentaron Consistency Flow Matching, una propuesta enfocada en construir trayectorias rectas mediante la aplicación de restricciones de consistencia en el campo de velocidad. A diferencia de otros enfoques que dependen principalmente de procesos iterativos para rectificar las trayectorias, esta metodología incorpora de manera explícita la consistencia de la velocidad para enlazar distintos momentos en el tiempo con un mismo destino final. Los autores argumentan que este mecanismo favorece la simplicidad de las trayectorias y posibilita una generación eficiente, requiriendo menos evaluaciones del campo vectorial. Así, su trabajo subraya que mantener trayectorias menos complejas sigue siendo clave para optimizar la velocidad de inferencia en los modelos basados en Flow Matching, aportando un enfoque novedoso en este ámbito.

Desde el enfoque teórico, Zhou and Liu (2025) analizaron el error presente en los modelos generativos desarrollados con Flow Matching. Su trabajo se centra en cómo la distribución generada se aproxima a la distribución objetivo y en qué condiciones se puede garantizar esta convergencia, utilizando como referencia la distancia de Wasserstein-2. Lo interesante de este antecedente es que permite separar claramente el error que proviene del aprendizaje del campo de velocidad de aquel que surge al resolver numéricamente la ecuación diferencial. Esta distinción resulta crucial para este proyecto, pues ayuda a entender mejor cómo el método de integración influye en la distribución final que se obtiene.

Finalmente, Xiao (2026) llevó a cabo un análisis comparativo de distintos métodos de integración numérica aplicados a modelos de Flow Matching. En su estudio, exploró alternativas como Euler, midpoint explícito, Runge-Kutta de cuarto orden y Dormand-Prince, realizando pruebas con distribuciones sintéticas bidimensionales. Al comparar la calidad de las muestras y la cantidad de evaluaciones requeridas del campo vectorial, notó que los métodos más avanzados pueden ser más eficientes sin comprometer la calidad de los resultados. De esta manera, su trabajo muestra cómo la elección del método de integración puede marcar diferencias sutiles pero importantes en el comportamiento práctico de estos modelos.

En conjunto, estos antecedentes sugieren que la eficiencia de los modelos basados en Flow Matching y Rectified Flow no depende únicamente de la capacidad del campo vectorial para transformar una distribución en otra. También influyen aspectos como la geometría de las trayectorias y el método numérico empleado para resolver la ecuación diferencial. Por esto, resulta interesante analizar cómo se comporta el modelo al mantener

constante el campo vectorial y variar únicamente el método de integración, lo que permite observar con mayor claridad cómo la discretización numérica afecta tanto la trayectoria como el resultado final y los recursos computacionales requeridos.

A pesar de los recientes y notables avances en los modelos generativos continuos, un inconveniente importante tanto de los Flujos Normalizantes Continuos (CNFs, descritos por EDOs) como de los modelos de difusión, también descritos por EDOs, es que su simulación e integración numérica requieren múltiples evaluaciones de la red neuronal para generar una muestra de alta calidad. Este proceso iterativo da como resultado tiempos de inferencia prolongados, lo que limita su eficiencia y aplicabilidad en escenarios de tiempo real. Para mitigar este inconveniente, investigaciones recientes han motivado el desarrollo de métodos que imponen propiedades de transporte óptimo (OT) en las EDOs neuronales, produciendo flujos con trayectorias más rectas que pueden integrarse con precisión utilizando un menor número de evaluaciones de la red neuronal. Sin embargo, la literatura carece de un análisis exhaustivo sobre cómo la elección específica del método de integración numérica altera la trayectoria, el error y el costo cuando se aplican estos flujos enderezados. El presente trabajo se justifica en la necesidad de llenar este vacío analizando el efecto del integrador numérico sobre modelos de flujo rectificado en un entorno controlado de distribuciones bidimensionales. Comprender la relación exacta entre la rectitud de la trayectoria, la precisión del integrador numérico y la eficiencia computacional es un paso indispensable para optimizar el despliegue de modelos generativos modernos.

Por lo expuesto, como objetivo general tenemos: modelar numéricamente el transporte continuo de muestras mediante ecuaciones diferenciales que transformen una distribución inicial simple en una distribución objetivo bidimensional, con el propósito de analizar la relación entre la precisión, la eficiencia computacional y la rectitud de las trayectorias generadas mediante diferentes campos vectoriales y métodos de integración. En base a ello desarrollamos nuestros objetivos específicos los cuales son:

1. Formular e implementar un modelo numérico basado en EDOs que represente el transporte de muestras desde una distribución inicial simple hacia una distribución objetivo bidimensional mediante campos vectoriales de prueba.
2. Evaluar el comportamiento del modelo bajo un conjunto base de parámetros, considerando la trayectoria de las muestras, el error respecto a la distribución objetivo y el costo computacional asociado al proceso de integración.
3. Analizar la robustez del modelo mediante la variación de parámetros relevantes, comparando los cambios en la precisión, la rectitud de las trayectorias y el costo computacional obtenidos bajo diferentes configuraciones.
4. Aplicar el modelo numérico al transporte de distribuciones bidimensionales para determinar la relación entre la rectitud de las trayectorias, el método de integración empleado y la eficiencia en la generación de muestras.

2. Metodología

2.1. Modelo del Sistema

El fenómeno de estudio se modela como un flujo continuo descrito por la Ecuación Diferencial Ordinaria (EDO):

$$\frac{dx_t}{dt} = v(x_t, t), \quad x_0 \sim \pi_0, \quad t \in [0, 1], \quad (1)$$

donde $x_t \in \mathbb{R}^2$ representa la posición de una partícula en el instante t , π_0 es una distribución inicial simple (una distribución Normal multivariada estándar $\mathcal{N}(0, I)$) y $v(x_t, t)$ es un campo vectorial de velocidad que transporta las muestras hacia una distribución objetivo bidimensional π_1 al tiempo $t = 1$. El punto parte de una posición inicial aleatoria en $t = 0$ y la simulación corre hasta $t = 1$, momento en el cual se espera que haya alcanzado la distribución objetivo.

Se consideran dos formas de definir el campo v : (a) un campo vectorial recto, construido mediante interpolación lineal $x_t = tx_1 + (1-t)x_0$ entre pares de puntos muestreados de π_0 y π_1 , cuya velocidad resulta constante e igual a $v = x_1 - x_0$; y (b) un campo vectorial curvo de referencia, que introduce no linealidad en la trayectoria. Esta idea de emplear una velocidad constante para trazar trayectorias rectas corresponde al principio central propuesto por Liu et al. (2022) en Rectified Flow y por Lipman et al. (2022) en Flow Matching. Cabe notar que, en ambos trabajos, el campo de velocidad se obtiene habitualmente entrenando una red neuronal $v_\theta(x, t)$ mediante regresión condicional; en el presente estudio se opta por campos definidos analíticamente en lugar de entrenar dicha red, con el fin de aislar el efecto del método de integración numérica sin introducir la variabilidad propia del proceso de aprendizaje, tal como se detalla en los Supuestos. Como distribuciones objetivo π_1 se emplean conjuntos de datos sintéticos bidimensionales y reproducibles: una mezcla de gaussianas y el conjunto conocido como *two moons*. Se usan ambas versiones del campo v a propósito, dado que el objetivo es comparar si la forma del camino (recto frente a curvo) afecta el resultado al cambiar el método de integración.

2.2. Supuestos y Simplificaciones

Se adoptan las siguientes simplificaciones respecto al problema general abordado en la literatura, con el fin de enfocar el análisis en el desempeño del integrador numérico:

- **Dimensionalidad reducida:** Se trabaja en dimensión $d = 2$, en lugar de las imágenes de alta dimensión reportadas en los artículos de referencia. Esto permite visualizar directamente las trayectorias individuales y las distribuciones resultantes, además de reducir la carga computacional necesaria para evaluar múltiples métodos numéricos.
- **Campos vectoriales analíticos:** Se emplean campos de velocidad definidos mediante una fórmula matemática conocida, en lugar de entrenar una red neuronal como en el objetivo de regresión condicional de Lipman et al. (2022). Esta simplificación es clave: al usar una fórmula fija, se conoce con exactitud la trayectoria correcta, de modo que

cualquier error observado en la distribución final se puede atribuir de forma predominante al método de integración numérica y no a un posible error de aprendizaje.

- **Suavidad del campo vectorial:** Se asume que los campos vectoriales considerados son suficientemente suaves, es decir, sin saltos ni cambios bruscos. Esto garantiza que la ecuación diferencial tenga una solución única en cada punto y evita que dos trayectorias distintas se crucen en el mismo lugar y momento, lo que haría ambigua la dirección del movimiento.
- **Ventaja de las trayectorias rectas:** Se asume que la rectitud de los flujos inducidos por Rectified Flow y Flow Matching reduce la curvatura del campo vectorial y, en consecuencia, el error de truncamiento local de los métodos numéricos, permitiendo el uso de tamaños de paso más grandes sin degradar significativamente la calidad de la solución.

2.3. Métodos Numéricos Propuestos

Para resolver la EDO planteada, la fase de generación requiere aproximar la solución desde $t = 0$ hasta $t = 1$. Se proponen tres esquemas de integración numérica que cubren distintos niveles de precisión y costo computacional.

Acorde a los lineamientos del curso, se emplean **dos métodos numéricos revisados en clase**:

1. **Método de Euler (primer orden):** Se implementa como método base de comparación. En cada paso, se calcula la velocidad actual y se avanza en línea recta ese intervalo temporal. Es el método más económico computacionalmente, pero se espera que presente un mayor error de truncamiento frente a tamaños de paso grandes, lo que permite evaluar qué tan permisivas resultan las trayectorias rectas frente a un integrador de bajo orden.
2. **Runge-Kutta de cuarto orden (RK4):** Se implementa como integrador de referencia de alta precisión. En cada paso evalúa la velocidad en cuatro puntos distintos y los combina para obtener una aproximación de mayor exactitud. Dado su mayor costo por iteración (cuatro evaluaciones del campo vectorial por paso), permite analizar el compromiso entre el costo computacional, medido como Número de Evaluaciones de la Función (NFE), y la precisión obtenida.

Como **método numérico no revisado explícitamente en clase**, se propone:

3. **Runge-Kutta adaptativo (RK45, Fehlberg/Dormand-Prince):** A diferencia de los métodos de paso fijo, este integrador calcula simultáneamente una aproximación de cuarto y quinto orden para estimar el error de truncamiento local en cada iteración, y ajusta dinámicamente el tamaño de paso en función de dicha estimación. Se propone este método porque permite evaluar el costo computacional real necesario para alcanzar una tolerancia de error determinada: en las zonas donde la trayectoria sea recta, el paso se agranda automáticamente, optimizando el NFE sin comprometer la precisión de la distribución final obtenida.

La elección de estos tres métodos responde directamente a los objetivos específicos (ii) y (iii) del estudio, pues permite construir curvas de error frente a costo computacional y analizar la sensibilidad del resultado final al tamaño de paso empleado, en línea con el análisis comparativo de integradores reportado por Xiao (2026) para modelos de flow matching.

References

- Lipman, Y., Chen, R. T. Q., Ben-Hamu, H., Nickel, M., Le, M., 2022. Flow matching for generative modeling. arXiv preprint arXiv:2210.02747. <https://doi.org/10.48550/arXiv.2210.02747>
- Liu, X., Gong, C., Liu, Q., 2022. Flow straight and fast: Learning to generate and transfer data with rectified flow. arXiv preprint arXiv:2209.03003. <https://doi.org/10.48550/arXiv.2209.03003>
- Pooladian, A.-A., Ben-Hamu, H., Domingo-Enrich, C., Amos, B., Lipman, Y., Chen, R. T. Q., 2023. Multisample flow matching: Straightening flows with minibatch couplings. In: Proceedings of the 40th International Conference on Machine Learning. PMLR, pp. 28100–28120. <https://proceedings.mlr.press/v202/pooladian23a.html>
- Tong, A., Fatras, K., Malkin, N., Huguet, G., Zhang, Y., Rector-Brooks, J., Wolf, G., Bengio, Y., 2023. Improving and generalizing flow-based generative models with minibatch optimal transport. arXiv preprint arXiv:2302.00482. <https://doi.org/10.48550/arXiv.2302.00482>
- Yang, L., Zhang, Z., Zhang, Z., Liu, X., Xu, M., Zhang, W., Meng, C., Ermon, S., Cui, B., 2024. Consistency flow matching: Defining straight flows with velocity consistency. arXiv preprint arXiv:2407.02398. <https://doi.org/10.48550/arXiv.2407.02398>
- Zhou, Z., Liu, W., 2025. An Error Analysis of Flow Matching for Deep Generative Modeling. In: Proceedings of the 42nd International Conference on Machine Learning. PMLR 267, 78903–78932. <https://proceedings.mlr.press/v267/zhou25l.html>
- Xiao, H., 2026. From Euler to Dormand-Prince: ODE Solvers for Flow Matching Generative Models. arXiv preprint arXiv:2605.00836. <https://arxiv.org/abs/2605.00836>