

Efecto del método de integración numérica en modelos de flujo rectificado sobre distribuciones bidimensionales

Integrantes del grupo:

Tommy Bryan Loo Leon - [202510241]
Jesús Valentín Niño Castañeda - [202310452]
Leonardo Jesús Medina Gago - [202410022]
Lemuel Uziel Ramos Urbano - [202520133]
Fabricio Joaquin Rueda Zapata - [202510114]

Curso:

CC2104 Métodos Numéricos

Profesor:

[Patricia Reynoso Quispe]

Fecha de entrega:

9 de Septiembre de 2026

Efecto del método de integración numérica en modelos de flujo rectificado sobre distribuciones bidimensionales

Tommy Bryan Loo Leon^a, Jesús Valentín Niño Castañeda^a, Leonardo Jesús Medina Gago^a, Lemuel Uziel Rambos Urbano^a,
Fabricio Joaquin Rueda Zapata^a

^aUTEC, , , , ,

Abstract

The project will study a continuous flow described by a differential equation that transports samples from a simple initial distribution to a two-dimensional target distribution. Instead of training a large-scale generative image model, we will implement different test vector fields or, alternatively, a small neural network to approximate the transport field and observe how the distribution evolves over time. We will use synthetic data and evaluate how the integrator affects the trajectory, final error, and computational cost. The ultimate goal will be to evaluate the relationship between accuracy and efficiency, identifying how important it is for the trajectories to be straight or close to the ideal trajectories. The theoretical foundation of the project will be related to papers that present different variants of rectified flow, flow matching, and straighter transport trajectories.

Keywords: Flow Matching, Rectified Flow, Integración Numérica, Modelos Generativos

1. Introduction

Muchos problemas modernos requieren transformar un conjunto de puntos, generados de manera simple y aleatoria, en otro conjunto de puntos que sigue una distribución mucho más compleja. Este tipo de transformación puede describirse mediante una ecuación diferencial ordinaria que indica, en cada instante de tiempo, la velocidad con la que cada punto debe desplazarse para alcanzar su posición final. Dado que estas ecuaciones diferenciales rara vez admiten una solución analítica exacta, resulta necesario resolverlas mediante métodos numéricos de integración, cuya elección determina de manera directa tanto la precisión de la trayectoria obtenida como el costo computacional del proceso. Este problema resulta particularmente relevante en el contexto de los modelos generativos modernos, en los cuales el transporte eficiente y preciso de distribuciones de probabilidad constituye un componente central.

Para profundizar en el tema, se han seleccionado trabajos recientes y relevantes que abordan distintos enfoques y avances en Flow Matching y métodos relacionados. Estos antecedentes permiten comprender la evolución de las ideas y los desafíos que se han presentado en el área.

Como primer antecedente, Lipman et al. (2022) introdujeron Flow Matching, un marco que permite entrenar campos vectoriales para modelar el transporte continuo entre una distribución inicial y una distribución objetivo mediante ecuaciones diferenciales ordinarias. Lo interesante de su propuesta es que posibilita definir diferentes trayectorias de probabilidad y entrenar el campo de velocidad sin necesidad de simular previamente dichas trayectorias durante el entrenamiento. Además, los autores muestran que los caminos basados en transporte óptimo pueden generar muestras de forma más rápida y eficiente en comparación con otras alternativas, gracias al uso de métodos

numéricos para resolver las ODE en la fase de muestreo, lo que proporciona la base conceptual y matemática sobre la que se apoyan los modelos de transporte analizados en este proyecto.

Posteriormente, Liu et al. (2022) propusieron Rectified Flow, cuyo objetivo es aprender trayectorias de transporte lo más rectas posible entre las distribuciones inicial y final. La idea principal consiste en emplear un campo de velocidad que aproxime la trayectoria lineal que une los puntos correspondientes de ambas distribuciones. Esta característica resulta especialmente interesante desde una perspectiva numérica, ya que una trayectoria recta permite una discretización temporal mucho más gruesa sin perder precisión. Los autores demostraron que, mediante el procedimiento llamado reflow, es posible obtener trayectorias cada vez más rectas y lograr buenos resultados incluso utilizando un solo paso de Euler, lo que implica que se pueden reducir considerablemente los pasos necesarios para la integración y, en consecuencia, el tiempo requerido para generar muestras.

En esta misma línea, Pooladian et al. (2023) desarrollaron Multisample Flow Matching, una extensión que introduce acoplamientos no triviales entre muestras de las distribuciones de origen y destino. El objetivo de esta propuesta es aprovechar la estructura existente entre las muestras para construir campos vectoriales con trayectorias más rectas. Los autores demostraron que, además de reducir la varianza durante el entrenamiento, este enfoque permite generar muestras de buena calidad utilizando un menor número de evaluaciones del campo vectorial, lo que evidencia experimentalmente que la geometría de las trayectorias puede influir de manera directa en la eficiencia computacional del proceso de integración, y resalta la importancia de considerar este aspecto en el presente estudio.

De manera relacionada, Tong et al. (2023) exploraron el uso

del transporte óptimo dentro de Flow Matching a través de su propuesta llamada Optimal Transport Conditional Flow Matching. En su estudio, los autores muestran que los acoplamientos obtenidos mediante transporte óptimo permiten construir flujos más simples y estables, además de facilitar una inferencia más rápida. Estos resultados refuerzan la idea de que la manera en que se establece la correspondencia entre las distribuciones inicial y objetivo influye directamente en la complejidad del campo vectorial y, por lo tanto, en la dificultad de su resolución numérica, lo que resulta especialmente relevante para el análisis realizado en este proyecto.

Posteriormente, Yang et al. (2024) presentaron Consistency Flow Matching, una propuesta enfocada en construir trayectorias rectas mediante la aplicación de restricciones de consistencia en el campo de velocidad. A diferencia de otros enfoques que dependen principalmente de procesos iterativos para rectificar las trayectorias, esta metodología incorpora de manera explícita la consistencia de la velocidad para enlazar distintos momentos en el tiempo con un mismo destino final. Los autores argumentan que este mecanismo favorece la simplicidad de las trayectorias y posibilita una generación eficiente, requiriendo menos evaluaciones del campo vectorial. Así, su trabajo subraya que mantener trayectorias menos complejas sigue siendo clave para optimizar la velocidad de inferencia en los modelos basados en Flow Matching, aportando un enfoque novedoso en este ámbito.

Desde el enfoque teórico, Zhou and Liu (2025) analizaron el error presente en los modelos generativos desarrollados con Flow Matching. Su trabajo se centra en cómo la distribución generada se aproxima a la distribución objetivo y en qué condiciones se puede garantizar esta convergencia, utilizando como referencia la distancia de Wasserstein-2. Lo interesante de este antecedente es que permite separar claramente el error que proviene del aprendizaje del campo de velocidad de aquel que surge al resolver numéricamente la ecuación diferencial. Esta distinción resulta crucial para este proyecto, pues ayuda a entender mejor cómo el método de integración influye en la distribución final que se obtiene.

Finalmente, Xiao (2026) llevó a cabo un análisis comparativo de distintos métodos de integración numérica aplicados a modelos de Flow Matching. En su estudio, exploró alternativas como Euler, midpoint explícito, Runge-Kutta de cuarto orden y Dormand-Prince, realizando pruebas con distribuciones sintéticas bidimensionales. Al comparar la calidad de las muestras y la cantidad de evaluaciones requeridas del campo vectorial, notó que los métodos más avanzados pueden ser más eficientes sin comprometer la calidad de los resultados. De esta manera, su trabajo muestra cómo la elección del método de integración puede marcar diferencias sutiles pero importantes en el comportamiento práctico de estos modelos.

En conjunto, estos antecedentes sugieren que la eficiencia de los modelos basados en Flow Matching y Rectified Flow no depende únicamente de la capacidad del campo vectorial para transformar una distribución en otra. También influyen aspectos como la geometría de las trayectorias y el método numérico empleado para resolver la ecuación diferencial. Por esto, resulta interesante analizar cómo se comporta el modelo al mantener

constante el campo vectorial y variar únicamente el método de integración, lo que permite observar con mayor claridad cómo la discretización numérica afecta tanto la trayectoria como el resultado final y los recursos computacionales requeridos.

A pesar de los recientes y notables avances en los modelos generativos continuos, un inconveniente importante tanto de los Flujos Normalizantes Continuos (CNFs, descritos por EDOs) como de los modelos de difusión, también descritos por EDOs, es que su simulación e integración numérica requieren múltiples evaluaciones de la red neuronal para generar una muestra de alta calidad. Este proceso iterativo da como resultado tiempos de inferencia prolongados, lo que limita su eficiencia y aplicabilidad en escenarios de tiempo real. Para mitigar este inconveniente, investigaciones recientes han motivado el desarrollo de métodos que imponen propiedades de transporte óptimo (OT) en las EDOs neuronales, produciendo flujos con trayectorias más rectas que pueden integrarse con precisión utilizando un menor número de evaluaciones de la red neuronal. Sin embargo, la literatura carece de un análisis exhaustivo sobre cómo la elección específica del método de integración numérica altera la trayectoria, el error y el costo cuando se aplican estos flujos enderezados. El presente trabajo se justifica en la necesidad de llenar este vacío analizando el efecto del integrador numérico sobre modelos de flujo rectificado en un entorno controlado de distribuciones bidimensionales. Comprender la relación exacta entre la rectitud de la trayectoria, la precisión del integrador numérico y la eficiencia computacional es un paso indispensable para optimizar el despliegue de modelos generativos modernos.

Por lo expuesto, como objetivo general tenemos: modelar numéricamente el transporte continuo de muestras mediante ecuaciones diferenciales que transformen una distribución inicial simple en una distribución objetivo bidimensional, con el propósito de analizar la relación entre la precisión, la eficiencia computacional y la rectitud de las trayectorias generadas mediante diferentes campos vectoriales y métodos de integración. En base a ello desarrollamos nuestros objetivos específicos los cuales son:

1. Formular e implementar un modelo numérico basado en EDOs que represente el transporte de muestras desde una distribución inicial simple hacia una distribución objetivo bidimensional mediante campos vectoriales de prueba.
2. Evaluar el comportamiento del modelo bajo un conjunto base de parámetros, considerando la trayectoria de las muestras, el error respecto a la distribución objetivo y el costo computacional asociado al proceso de integración.
3. Analizar la robustez del modelo mediante la variación de parámetros relevantes, comparando los cambios en la precisión, la rectitud de las trayectorias y el costo computacional obtenidos bajo diferentes configuraciones.
4. Aplicar el modelo numérico al transporte de distribuciones bidimensionales para determinar la relación entre la rectitud de las trayectorias, el método de integración empleado y la eficiencia en la generación de muestras.

2. Metodología

2.1. Modelo del Sistema

El desarrollo de este proyecto se fundamenta en la formulación de Modelos Generativos Continuos (como Continuous Normalizing Flows), los cuales modelan la transformación progresiva de una densidad de probabilidad empírica a través del tiempo. Teóricamente, la evolución de esta densidad de probabilidad $p_t(x)$ en el tiempo $t \in [0, 1]$ está gobernada rigurosamente por la ecuación de continuidad (o ecuación de transporte):

$$\frac{\partial p_t(x)}{\partial t} + \nabla \cdot (p_t(x)v_t(x)) = 0 \quad (1)$$

donde el primer término representa la variación temporal de la densidad de probabilidad local, y el segundo término es la divergencia espacial del flujo de probabilidad. Esta Ecuación en Derivadas Parciales (EDP) asegura la conservación de la masa (probabilidad), determinando cómo el campo de velocidades $v_t(x)$ acumula o dispersa la distribución en el espacio.

Para evitar la alta complejidad computacional de resolver la EDP directamente, el sistema se aborda desde una perspectiva lagrangiana. El transporte continuo se describe de manera equivalente mediante el seguimiento de trayectorias individuales a través de la siguiente Ecuación Diferencial Ordinaria (EDO):

$$\frac{dZ_t}{dt} = v_\theta(Z_t, t), \quad Z_0 \sim \pi_0 \quad (2)$$

El problema central consiste en encontrar un campo vectorial aproximado por una red neuronal, $v_\theta(Z_t, t)$, que permita transportar muestras desde una distribución inicial simple y tratable π_0 (ruido gaussiano) hacia la distribución objetivo π_1 (los datos a generar). La solución en el instante $t = 1$, denotada como Z_1 , sigue la distribución empírica de los datos.

Para entrenar v_θ sin resolver iterativamente la EDO durante la optimización, se emplean enfoques de emparejamiento libre de simulación (*simulation-free*). Bajo el marco de Rectified Flow, el objetivo es conectar las muestras $X_0 \sim \pi_0$ y $X_1 \sim \pi_1$ mediante una interpolación lineal $X_t = tX_1 + (1-t)X_0$. La red se optimiza resolviendo el problema de mínimos cuadrados:

$$\min_{\theta} \int_0^1 \mathbb{E} [\|X_1 - X_0 - v_\theta(X_t, t)\|^2] dt \quad (3)$$

Equivalentemente, el marco de Flow Matching define una ruta de probabilidad condicional basada en Transporte Óptimo. Ambos enfoques garantizan matemáticamente que el transporte de partículas ocurra en líneas rectas y a velocidad constante, lo que simplifica la topología del campo vectorial y reduce drásticamente la dificultad de la integración numérica durante la fase de inferencia.

2.2. Supuestos y Simplificaciones

Para garantizar un entorno controlado que permita aislar y evaluar cuantitativamente el desempeño de los integradores numéricos sin la interferencia de factores ajenos al campo vectorial, se adoptan los siguientes supuestos teóricos y simplificaciones metodológicas, junto con sus respectivas limitaciones:

- **Suavidad y regularidad del campo vectorial (Condición de Lipschitz):** Se asume que el campo vectorial $v_\theta(x, t)$ parametrizado por la red neuronal es continuo y satisface la condición de Lipschitz respecto a x en el dominio compacto $\Omega \times [0, 1]$, es decir, $\|v_\theta(x, t) - v_\theta(y, t)\| \leq L\|x - y\|$ para alguna constante de Lipschitz $L > 0$. Este supuesto es fundamental para garantizar matemáticamente la existencia y unicidad de las trayectorias continuas Z_t (Teorema de Picard-Lindelöf), así como la estabilidad de los métodos numéricos de Euler y Runge-Kutta Lipman et al. (2022).

Limitación: En la práctica, las aproximaciones mediante redes neuronales no acotadas pueden presentar discontinuidades locales o gradientes elevados en regiones de baja densidad de datos, lo que potencialmente incrementa el error de truncamiento local en pasos dt grandes.

- **Precisión e independización del entrenamiento:** Se asume que la red neuronal aproxima con suficiente exactitud el campo de velocidad ideal $v(x, t)$ tras la fase de optimización. En consecuencia, se asume que cualquier desviación o error observado en la distribución final generada Z_1 respecto a la distribución objetivo π_1 se atribuye predominantemente al error de discretización del integrador numérico y no a un déficit de capacidad del modelo generativo.

Limitación: Si el entrenamiento incurre en un error residual de regresión $MSE > 0$, existe una frontera de error irreducible inherente al campo aprendido que ningún método de integración numérica puede corregir.

- **Naturaleza determinista del flujo (Ausencia de difusividad estocástica):** A diferencia de los modelos de difusión estocástica tradicionales basados en Ecuaciones Diferenciales Estocásticas (SDE), el marco de *Flow Matching* y *Rectified Flow* modela el transporte mediante una EDO puramente determinista Liu et al. (2022). Se asume que no existen perturbaciones estocásticas durante la integración temporal de las partículas desde $t = 0$ hasta $t = 1$.

Limitación: Aunque esta naturaleza determinista habilita el uso de integradores de EDOs estándar (Euler, RK4, RK45), elimina el efecto autorregulador que el ruido estocástico suele aportar frente a pequeñas desviaciones en la trayectoria.

- **Dimensionalidad reducida y datos sintéticos 2D:** Se asume que el análisis del transporte numérico sobre distribuciones empíricas bidimensionales (tales como *moons* u *8-gaussians*) refleja la dinámica cualitativa y cuantitativa de los flujos continuos de probabilidad. Esta simplificación permite visualizar de forma directa la geometría de las trayectorias y calcular de manera exacta los indicadores de costo computacional y error geométrico.

Limitación: La baja dimensionalidad reduce los problemas de mal acondicionamiento matricial y rigidez (*stiffness*) que suelen emerger en espacios de alta dimensión (p. ej., imágenes de alta resolución), por lo que las tasas

de convergencia observadas representan un escenario idealizado.

- **Distribución base canónica:** Se adopta como distribución inicial π_0 una distribución Normal multivariada estándar $\mathcal{N}(0, I)$, facilitando el muestreo de condiciones iniciales Z_0 independientes e idénticamente distribuidas.

Limitación: Muestras iniciales atípicos en las colas de la distribución gaussiana pueden requerir trayectorias de integración más extensas, exigiendo mayor adaptación en solucionadores de paso adaptativo.

- **Arquitectura de red no convolucional (Aproximación por MLP):** Dado que las distribuciones objetivo son conjuntos de puntos bidimensionales continuos $(x_1, x_2) \in \mathbb{R}^2$ y no imágenes o datos estructurados en grillas espaciales, se asume que el campo de velocidad $v_\theta(x, t)$ se parametriza adecuadamente mediante un Perceptrón Multicapa (MLP) liviano con activaciones suaves (ej. Softplus o SiLU), en lugar de una red neuronal convolucional (CNN) o U-Net.

Limitación: Aunque el MLP simplifica drásticamente el entrenamiento y la evaluación en MATLAB, no posee la inductiva de invarianza espacial propia de las CNNs, lo que limita este modelo a problemas de baja dimensión.

- **Formulación determinista frente a Modelos de Difusión Estocásticos:** Se adopta el supuesto de que el transporte de probabilidad se rige por la ODE de flujo de probabilidad determinista de *Flow Matching*, prescindiendo del término de difusión estocástica $\sigma(t)dW_t$ propio de los modelos de difusión tradicionales (SDEs/DDPM) Lipman et al. (2022). Asimismo, se asume que el entrenamiento mediante regresión de campos vectoriales condicionales (MSE) reemplaza con suficiente precisión el aprendizaje por estimación de *score* (*score-based diffusion*).

Limitación: Al eliminar la estocasticidad durante el muestreo, el modelo pierde el efecto de "autocorrección" de ruido que poseen las SDEs, haciendo que la precisión de la trayectoria dependa exclusivamente de la estabilidad del integrador numérico elegido (Euler, RK4 o RK45).

2.3. Métodos Numéricos Propuestos

Una vez que el modelo ha sido entrenado y el campo vectorial $v_\theta(Z_t, t)$ se encuentra definido, la fase de generación (inferencia) requiere aproximar la solución de la EDO desde $t = 0$ hasta $t = 1$. Para este propósito, se propone implementar y evaluar comparativamente tres métodos numéricos de un paso para problemas de valor inicial (PVI).

Acorde a los lineamientos del curso, se proponen **dos métodos numéricos revisados en clase:**

1. **Método de Euler (Primer Orden):** Se implementa como el método base de comparación (baseline). Al ser el método explícito más sencillo y de paso fijo, se espera que presente un alto error de truncamiento frente a tamaños de paso grandes, permitiendo evaluar qué tan permisivas son las trayectorias rectas frente a integradores de bajo orden computacional.

2. **Método de Runge-Kutta de Cuarto Orden (RK4):** Se implementa como el integrador de alta precisión revisado en el curso. Su evaluación permitirá establecer un estándar de alta calidad visual de las muestras generadas de forma estática. Dado su mayor costo por iteración (cuatro evaluaciones de la función v_θ por paso temporal fijo), servirá para analizar críticamente el compromiso entre costo computacional (Número de Evaluaciones de la Función, NFE) y precisión.

Para complementar el análisis, se propone implementar **un método numérico no revisado explícitamente en clase:**

3. **Método de Runge-Kutta Adaptativo (RK45 - Fehlberg / Dormand-Prince):** A diferencia de los métodos de paso fijo, este método empotrado calcula simultáneamente una aproximación de cuarto y quinto orden para estimar el error de truncamiento local en cada iteración. Esto permite adaptar dinámicamente el tamaño del paso temporal dt . Se propone este método porque es altamente eficiente para EDOs bien comportadas; en las zonas donde las trayectorias del modelo generativo sean efectivamente rectas, el RK45 aumentará automáticamente el tamaño de paso, optimizando el costo computacional (minimizando el NFE) sin comprometer la estricta tolerancia de error ni la precisión de la distribución generada Z_1 .

References

- Lipman, Y., Chen, R. T. Q., Ben-Hamu, H., Nickel, M., Le, M., 2022. Flow matching for generative modeling. arXiv preprint arXiv:2210.02747. <https://doi.org/10.48550/arXiv.2210.02747>
- Liu, X., Gong, C., Liu, Q., 2022. Flow straight and fast: Learning to generate and transfer data with rectified flow. arXiv preprint arXiv:2209.03003. <https://doi.org/10.48550/arXiv.2209.03003>
- Pooladian, A.-A., Ben-Hamu, H., Domingo-Enrich, C., Amos, B., Lipman, Y., Chen, R. T. Q., 2023. Multisample flow matching: Straightening flows with minibatch couplings. In: Proceedings of the 40th International Conference on Machine Learning. PMLR, pp. 28100–28120. <https://proceedings.mlr.press/v202/pooladian23a.html>
- Tong, A., Fatras, K., Malkin, N., Huguet, G., Zhang, Y., Rector-Brooks, J., Wolf, G., Bengio, Y., 2023. Improving and generalizing flow-based generative models with minibatch optimal transport. arXiv preprint arXiv:2302.00482. <https://doi.org/10.48550/arXiv.2302.00482>
- Yang, L., Zhang, Z., Zhang, Z., Liu, X., Xu, M., Zhang, W., Meng, C., Ermon, S., Cui, B., 2024. Consistency flow matching: Defining straight flows with velocity consistency. arXiv preprint arXiv:2407.02398. <https://doi.org/10.48550/arXiv.2407.02398>

Zhou, Z., Liu, W., 2025. An Error Analysis of Flow Matching for Deep Generative Modeling. In: Proceedings of the 42nd International Conference on Machine Learning. PMLR 267, 78903–78932. <https://proceedings.mlr.press/v267/zhou251.html>

Xiao, H., 2026. From Euler to Dormand-Prince: ODE Solvers for Flow Matching Generative Models. arXiv preprint arXiv:2605.00836. <https://arxiv.org/abs/2605.00836>